

Anlamsal Arama ve Belge Getirme Sistemi: BM25, Sentence-BERT ve Multilingual-E5'in Karşılaştırmalı Analizi

Ahmetcan PEKTAŞ

Bilgisayar Mühendisliği Ana Bilim Dalı YL, Mühendislik Fakültesi, Bandırma Onyedi Eylül Üniversitesi, Balıkesir, Türkiye
ahmetcanpektas@ogr.bandirma.edu.tr

Kod ve çıktılarına sağ üstteki github linkinden ulaşabilirsiniz.

Tarih: 20.06.2026

Abstract: In this study, a semantic search and passage retrieval system was developed to return the most relevant passages for natural language user queries. The Turkish machine-translated version of the MS MARCO passage ranking collection, msmarco-tr, was used, and an evaluation dataset consisting of 40,000 passages and 921 queries was constructed. BM25 was employed as the classical information retrieval baseline, while Sentence-BERT MiniLM, multilingual-E5-base, and multilingual-E5-large were compared as semantic retrieval models using a FAISS-based vector index. The models were evaluated using Precision@k, Recall@k, MRR, and nDCG metrics. Experimental results showed that the general-purpose MiniLM model performed worse than BM25, whereas the E5 models, specifically designed for information retrieval tasks, achieved significantly better results. E5-base reached an MRR of 0.798 and a Recall@10 of 0.924, while E5-large achieved the best performance with an MRR of 0.839 and a Recall@10 of 0.943. Furthermore, the analysis revealed that BM25 performs better on short and keyword-oriented queries, whereas dense vector models are more effective for longer queries and queries expressing the same meaning using different words. Overall, the findings indicate that retrieval performance depends more on the suitability of the representation model to the task than on the amount of data.

Keywords: Information Retrieval, Semantic Search, Passage Retrieval, BM25, Sentence-BERT, Multilingual-E5, FAISS, MS MARCO, Turkish Natural Language Processing.

Anlamsal Arama ve Belge Getirme Sistemi: BM25, Sentence-BERT ve Multilingual-E5'in Karşılaştırmalı Analizi

Özet: Bu çalışmada, kullanıcının doğal dilde yazdığı sorgulara en alakalı pasajları döndüren bir anlamsal arama ve belge getirme sistemi geliştirilmiştir. Veri seti olarak MS MARCO passage-ranking koleksiyonunun Türkçe makine çevirisi olan msmarco-tr kullanılmış, değerlendirme amacıyla 40.000 pasaj ve 921 sorgudan oluşan bir veri kümesi oluşturulmuştur. Klasik bilgi erişim yöntemi olarak BM25, anlamsal arama yöntemleri olarak ise Sentence-BERT MiniLM, multilingual-E5-base ve multilingual-E5-large modelleri FAISS tabanlı vektör indeksi üzerinde karşılaştırılmıştır. Modeller Precision@k, Recall@k, MRR ve nDCG metrikleri ile değerlendirilmiştir. Sonuçlar, genel amaçlı MiniLM modelinin BM25 yönteminin gerisinde kaldığını, buna karşılık bilgi erişim görevleri için geliştirilen E5 modellerinin daha yüksek başarı sağladığını göstermiştir. E5-base modeli 0,798 MRR ve 0,924 Recall@10 değerlerine ulaşırken, E5-large modeli 0,839 MRR ve 0,943 Recall@10 ile en yüksek performansı elde etmiştir. Ayrıca yapılan analizler, BM25 yönteminin kısa ve anahtar kelime içeren sorgularda daha başarılı olduğunu, yoğun vektör tabanlı modellerin ise daha uzun ve aynı anlamı farklı kelimelerle ifade eden sorgularda daha iyi sonuç verdiğini göstermiştir. Elde edilen bulgular, belge getirme başarısında veri miktarından çok kullanılan modelin probleme uygunluğunun belirleyici olduğunu ortaya koymaktadır.

Anahtar Kelimeler: Bilgi Erişimi, Anlamsal Arama, Belge Getirme, BM25, Sentence-BERT, Multilingual-E5, FAISS, MS MARCO, Türkçe Doğal Dil İşleme.

1. Giriş

1.1. Problem Tanımı

Bilgi erişimi (Information Retrieval, IR), bir kullanıcı sorgusuna karşılık büyük bir belge koleksiyonu içerisinde en alakalı belgelerin veya pasajların bulunması ve önem derecelerine göre sıralanması problemi [1]. Klasik bilgi erişim yöntemleri olan TF-IDF ve BM25, sorgu ile belge arasındaki ilişkiyi büyük ölçüde kelime düzeyindeki örtüşmeye dayalı olarak modellemektedir [2]. Bu yaklaşım, aynı bilgi ihtiyacının farklı ifadelerle dile getirildiği veya sorgu ile ilgili belge arasında doğrudan kelime benzerliğinin bulunmadığı durumlarda yetersiz kalabilmektedir. Bu çalışmanın amacı, sorgunun anlamsal içeriğini dikkate alarak yalnızca kelime eşleşmesine bağlı kalmayan bir belge getirme sistemi geliştirmek ve bu sistemi klasik bir bilgi erişim yöntemi ile aynı koşullar altında karşılaştırmalı olarak değerlendirmektir.

1.2. Motivasyon

Anlamsal arama sistemleri, soru-cevap sistemleri, kurumsal doküman arama uygulamaları ve Retrieval-Augmented Generation (RAG) mimarilerinin bilgi erişim katmanında önemli bir rol oynamaktadır [3], [4]. Özellikle Türkçe gibi eklemeli yapıya sahip ve biçimbilimsel açıdan zengin dillerde, yalnızca kelime eşleşmesine dayanan yöntemler sorgu ile ilgili içerik arasındaki ilişkiyi her zaman doğru biçimde kuramayabilmektedir. Bu nedenle, anlamsal temsil yöntemlerinin Türkçe üzerindeki başarısının incelenmesi hem akademik hem de uygulamalı çalışmalar açısından önem taşımaktadır.

1.3. Hedef Kullanıcı ve Senaryo

Bu çalışmada geliştirilen sistem, doğal dilde sorgular kullanarak büyük belge koleksiyonları içerisinde arama yapmak isteyen kullanıcıları hedeflemektedir. Kullanıcılar; yönetmelikler, sık sorulan sorular, ders notları veya benzeri metin koleksiyonları içerisinde ihtiyaç duydukları bilgilere doğal cümleler kullanarak ulaşabilmektedir. Geleneksel anahtar kelime tabanlı arama yöntemleri, kullanıcı sorgularında kullanılan ifadeler ile ilgili belgelerdeki ifadeler birebir örtüşmediğinde yetersiz kalabilmektedir. Bu nedenle, kullanıcıların sorgularını doğal dilde ifade ettiği ve ilgili bilginin farklı kelimelerle aktarılabilirdiği senaryolarda, anlamsal arama yöntemlerinin etkinliği önem kazanmaktadır. Ayrıca geliştirilen yaklaşım, soru-cevap sistemleri ve Retrieval-Augmented Generation (RAG) tabanlı uygulamalar gibi ilgili belge veya bağlamın önceden belirlenmesini gerektiren sistemlerde de kullanılabilecek bir belge getirme mekanizması temeli sunmaktadır.

1.4. Çalışmanın Katkıları

Bu çalışmada, Türkçe msmarco-tr veri seti üzerinde tekrar üretilebilir bir değerlendirme ortamı oluşturulmuş ve klasik bilgi erişim yöntemleri ile yoğun vektör temsillerine dayalı yaklaşımlar aynı koşullar altında karşılaştırılmıştır. Bu kapsamda, sözlüksel bir yöntem olan BM25 ile genel amaçlı bir cümle benzerliği modeli olan MiniLM ve bilgi erişim görevleri için özel olarak geliştirilen multilingual-E5 modellerinin performansları incelenmiştir. Ayrıca, genel amaçlı cümle benzerliği modellerinin bilgi erişim problemlerinde her zaman üstün sonuç vermediği deneysel olarak gösterilmiş, farklı sorgu türleri üzerinde yapılan analizlerle sözlüksel ve anlamsal yöntemlerin güçlü ve zayıf yönleri ortaya konmuştur. Elde edilen bulgular, bilgi erişim görevleri için özel olarak eğitilen modellerin daha tutarlı ve yüksek performans sağladığını göstermektedir.

2. İlgili Çalışmalar

Bilgi erişimi alanında uzun yıllardır kullanılan klasik yöntemler, sorgu ile belge arasındaki ilişkiyi kelime düzeyindeki eşleşmelere dayalı olarak modellemektedir. Manning ve arkadaşları [1], bilgi erişim sistemlerinin temel prensiplerini ve değerlendirme yöntemlerini kapsamlı biçimde ele almışlardır. Bu alanda en yaygın kullanılan yöntemlerden biri olan BM25, Robertson ve Zaragoza tarafından geliştirilen olasılıksal alaka çerçevesine dayanmakta olup, terim sıklığı ve belge uzunluğu normalizasyonunu dikkate alarak güçlü ve yorumlanabilir bir temel yöntem olarak günümüzde de yaygın biçimde kullanılmaktadır [2].

Derin öğrenme temelli dil modellerinin gelişmesiyle birlikte, metinlerin anlamsal özelliklerini temsil edebilen yoğun vektör temelli yaklaşımlar bilgi erişim alanında önemli bir ilerleme sağlamıştır. BERT modeli, bağlamsal dil temsilleri konusunda önemli bir dönüm noktası olmuş ve birçok doğal dil işleme görevinde yüksek başarı elde etmiştir [5]. Reimers ve Gurevych [6] tarafından önerilen Sentence-BERT yaklaşımı, BERT modelini cümle benzerliği problemlerine uyarlayarak sabit boyutlu cümle temsilleri üretmeyi mümkün kılmıştır. Daha sonra Karpukhin ve arkadaşları [3], sorgu ve belgeleri ayrı kodlayıcılar aracılığıyla temsil eden Dense Passage Retrieval (DPR) yaklaşımını önererek yoğun vektör tabanlı bilgi erişim yöntemlerinin açık alan soru-cevap sistemlerindeki başarısını göstermiştir.

Wang ve arkadaşları [7], zayıf denetimli karşılaştırmalı öğrenme yaklaşımıyla E5 gömme modellerini geliştirmiş ve bu modellerin bilgi erişim görevlerinde güçlü sonuçlar verdiğini göstermiştir. E5 modelinin çok dilli sürümü olan multilingual-E5 ise XLM-RoBERTa tabanlı yapısı sayesinde farklı dillerde anlamsal benzerlikleri başarıyla temsil edebilmekte ve sorgu ile belge arasındaki ilişkiyi daha etkili biçimde modelleyebilmektedir [4], [8].

Yoğun vektör temelli yöntemlerin büyük ölçekli veri kümelerinde verimli biçimde kullanılabilmesi için uygun indeksleme mekanizmalarına ihtiyaç duyulmaktadır. Johnson ve arkadaşları [9] tarafından geliştirilen FAISS kütüphanesi, milyonlarca vektör üzerinde hızlı benzerlik araması yapılmasına olanak sağlayarak modern anlamsal arama sistemlerinin temel bileşenlerinden biri haline gelmiştir.

Bu çalışmada kullanılan veri setinin temelini, Nguyen ve arkadaşları [10] tarafından geliştirilen MS MARCO veri kümesi oluşturmaktadır. MS MARCO, gerçek kullanıcı sorgularından elde edilen büyük ölçekli bir pasaj sıralama veri kümesidir. Bonifacio ve arkadaşları [11], bu veri kümesini çok dilli hale getirerek mMARCO veri setini oluşturmuşlardır. Bu çalışmada ise Parsak [12] tarafından geliştirilen Türkçe uyarlama olan msmarco-tr veri seti kullanılmıştır.

Bilgi erişim sistemlerinin değerlendirilmesinde sıralama kalitesini ölçen nDCG metriği Järvelin ve Kekäläinen [13] tarafından önerilmiş olup, günümüzde standart değerlendirme ölçütlerinden biri olarak kabul edilmektedir. Thakur ve arkadaşları [14] tarafından geliştirilen BEIR çerçevesi ise gömme tabanlı bilgi erişim modellerinin farklı veri kümeleri üzerindeki başarısını karşılaştırmak amacıyla yaygın olarak kullanılmaktadır. Ayrıca, farklı erişim yöntemlerinin sonuçlarını birleştirmek için kullanılan Reciprocal Rank Fusion yöntemi, Cormack ve arkadaşları [15] tarafından önerilmiş ve basit yapısına rağmen etkili sonuçlar verdiği gösterilmiştir.

3. Veri Seti

3.1. Veri Seti Kaynağı ve Yapısı

Bu çalışmada, MS MARCO passage-ranking veri setinin Türkçeye makine çevirisiyle oluşturulan msmarco-tr veri seti kullanılmıştır [12]. Veri seti üç temel bileşenden oluşmaktadır: Aranacak belge koleksiyonunu içeren passages alt kümesi, doğal dilde oluşturulmuş sorguları içeren queries alt kümesi ve sorgular ile ilgili pasajlar arasındaki ilişkiyi tanımlayan qrels alt kümesi. Sınıflandırma problemlerinden farklı olarak, bilgi erişim problemlerinde etiketler belirli sınıfları değil, sorgu ve belge arasındaki ilgililik ilişkisini temsil etmektedir. Bu yapı, Precision@k, Recall@k, Mean Reciprocal Rank (MRR) ve nDCG gibi sıralama temelli değerlendirme ölçütlerinin doğrudan hesaplanmasına olanak sağlamaktadır.

Koleksiyon toplam 718.217 pasaj, 501.428 eğitim sorgusu, 101.605 doğrulama sorgusu ve 532.761 ilgililik etiketinden oluşmaktadır. Örneğin, "Manhattan Projesi'nin başarısının hemen etkisi neydi?" şeklindeki bir sorgu, qrels kümesi aracılığıyla Manhattan Projesi ile ilgili uygun bir pasajla eşleştirilmektedir.

3.2. Değerlendirme Kümesinin Oluşturulması

Bu çalışmada kullanılan yöntemler veri kümesi üzerinde yeniden eğitilmemiş, BM25 yöntemi yalnızca belge koleksiyonu üzerinde indeksleme amacıyla kullanılmış, yoğun vektör tabanlı modeller ise önceden eğitilmiş biçimde değerlendirilmiştir. Bu nedenle klasik anlamda eğitim ve test ayrımı yerine, bilgi erişim problemlerine uygun bir değerlendirme düzeni oluşturulmuştur.


Değerlendirme amacıyla veri setinden belirli sayıda sorgu seçilmiş ve bu sorgularla ilişkili pasajlar ile rastgele seçilen ek pasajlar bir araya getirilerek 40.000 pasajdan oluşan bir arama koleksiyonu oluşturulmuştur. Seçilen sorguların bir kısmına ait ilgili pasajların koleksiyonda bulunmaması nedeniyle, yalnızca ilgili pasajı koleksiyon içerisinde yer alan 921 sorgu nihai değerlendirme kümesine dâhil edilmiştir. Böylece, tüm yöntemler aynı arama uzayı üzerinde karşılaştırılmış ve deneylerin tekrar üretilebilir olması sağlanmıştır. İlgili pasajların bir kısmının veri kümesinde bulunmaması, elde edilen sonuçlar üzerinde belirli sınırlamalar oluşturmakta olup, bu durum ilerleyen bölümlerde ayrıntılı olarak tartışılmaktadır.

3.3. Veri İstatistikleri ve Ön İşleme

Değerlendirme kümesindeki sorguların uzunluğu incelendiğinde, sorguların genel olarak kısa yapıda olduğu görülmektedir. Sorgu uzunluğu medyanı 5 kelime, ortalama uzunluk ise 4,8 kelime olup en uzun sorgu 14 kelimeden oluşmaktadır. Pasajlar ise birkaç cümleden oluşan daha uzun metinlerdir; pasaj uzunluğunun medyanı 40 kelime, ortalama uzunluğu ise 41,7 kelimedir. Ayrıca sorgu başına ilgili pasaj sayısının oldukça düşük olduğu gözlemlenmiştir. Değerlendirme kümesinde sorgu başına ilgili pasaj sayısının medyanı 1, ortalama değeri 1,04 ve en yüksek değeri 3'tür. Başka bir ifadeyle, sorguların büyük çoğunluğu yalnızca bir ilgili pasaj ile ilişkilidir. Bu durum, Precision@10 değerinin doğal olarak düşük görünmesine neden olmakta ve bilgi erişim performansının değerlendirilmesinde MRR, Recall@10 ve nDCG gibi sıralama temelli ölçütlerin daha anlamlı hale gelmesini sağlamaktadır.

Bilgi erişim yöntemlerinin uygulanmasından önce veri üzerinde gerekli ön işleme adımları gerçekleştirilmiştir. BM25 modelinde kullanılan sözcük tabanlı yaklaşım için Türkçeye uygun küçük harfe dönüştürme işlemi uygulanmıştır. Özellikle Türkçedeki "I" ve "İ" harflerinin farklı karşılıkları dikkate alınarak, hatalı dönüştürmelerin sorgu ve pasajlar arasındaki sözcük eşleşmesini olumsuz etkilemesi engellenmiştir. Yoğun vektör tabanlı modellerde ise modellerin kendi alt-kelime tabanlı ayrıştırma mekanizmaları kullanıldığından ek bir metin temizleme işlemine ihtiyaç duyulmamıştır.

Veri Seti İstatistikleri — değerlendirme alt-kümesi (921 sorgu, 40000 pasaj)



Şekil 1. Değerlendirme alt kümesindeki sorgu uzunlukları, pasaj uzunlukları ve sorgu başına ilgili pasaj sayısının dağılımı.

Yukarıdaki Şekil 1'de değerlendirme kümesindeki sorgu uzunlukları, pasaj uzunlukları ve sorgu başına düşen ilgili pasaj sayısının dağılımı gösterilmektedir. Görüldüğü üzere, sorguların büyük çoğunluğu kısa yapıda olup her sorgu için genellikle yalnızca bir ilgili pasaj bulunmaktadır.

4. Kullanılan Yöntemler

Bu bölümde, BM25, Sentence-BERT MiniLM, multilingual-E5-base ve multilingual-E5-large modellerinin belge getirme performansları karşılaştırılmıştır. Tüm yöntemler aynı belge koleksiyonu ve aynı sorgu kümesi üzerinde değerlendirilmiş, böylece yöntemler arasında adil ve tutarlı bir karşılaştırma yapılması amaçlanmıştır.

4.1. Klasik Yöntem: BM25

Klasik bilgi erişim yöntemi olarak BM25 kullanılmıştır. BM25, bir belgenin sorguyla olan ilişkisini sorgu terimlerinin belge içerisindeki sıklığı, terimlerin koleksiyondaki ayırt ediciliği ve belge uzunluğu gibi özellikleri dikkate alarak hesaplamaktadır [2]. Yöntem tamamen sözcük tabanlı olup sorgu ile belge arasındaki anlamsal ilişkiyi modellememektedir. Bu nedenle, aynı bilgi farklı ifadelerle aktarıldığında veya sorgu ile ilgili belge ortak kelimeler içermediğinde performansı sınırlı kalabilmektedir. BM25 modeli, Python ortamında rank-bm25 kütüphanesi kullanılarak gerçekleştirilmiştir.

4.2 Sentence-BERT Tabanlı Anlamsal Arama

Anlamsal arama yaklaşımı olarak ilk aşamada Sentence-BERT tabanlı paraphrase-multilingual-MiniLM-L12-v2 modeli kullanılmıştır [6]. Bu model, metinleri sabit boyutlu yoğun vektörler şeklinde temsil etmekte ve anlam bakımından benzer metinlerin vektör uzayında birbirine yakın konumlanmasını sağlamaktadır. Elde edilen vektörler, benzerlik aramasının hızlı bir şekilde gerçekleştirilebilmesi amacıyla FAISS kütüphanesi kullanılarak indekslenmiştir [9]. Böylece sorgu vektörleri ile belge vektörleri arasındaki benzerlik hesaplanarak en ilgili pasajlar elde edilmiştir.

4.3 Bilgi Erişimi İçin Geliştirilmiş Multilingual-E5 Modelleri

Çalışmada ayrıca bilgi erişim görevleri için özel olarak geliştirilen multilingual-E5-base ve multilingual-E5-large modelleri kullanılmıştır [4]. Bu modeller, sorgu ve belge temsillerini öğrenmeye yönelik olarak eğitilmiş olup, farklı dillerde anlamsal benzerlikleri başarılı bir şekilde modelleyebilmektedir. multilingual-E5-base modeli 768 boyutlu, multilingual-E5-large modeli ise 1024 boyutlu vektör temsilleri üretmektedir. Her iki model için elde edilen vektörler FAISS kullanılarak indekslenmiş ve sorgular ile belgeler arasındaki benzerlikler üzerinden en ilgili sonuçlar belirlenmiştir. Bu sayede, genel amaçlı bir cümle benzerliği modeli ile bilgi erişim görevine özel olarak geliştirilen modellerin performansları doğrudan karşılaştırılmıştır.

4.4. Kullanılan Araçlar ve Kütüphaneler

Çalışmada Python programlama dili kullanılmıştır. Veri kümesinin yönetimi için Hugging Face Datasets, önceden eğitilmiş modellerin kullanımı için Transformers ve Sentence-Transformers kütüphaneleri tercih edilmiştir. BM25 yöntemi rank-bm25, vektör indeksleme işlemleri FAISS, veri işleme aşamalarında NumPy ve pandas, görselleştirme işlemlerinde ise Matplotlib kütüphaneleri kullanılmıştır.

5. Deneysel Kurulum

Deneyler Google Colab ortamında NVIDIA GPU desteği ve PyTorch kütüphanesi kullanılarak gerçekleştirilmiştir. Çalışmada herhangi bir yeniden eğitim işlemi uygulanmamış, BM25 modeli doğrudan belge koleksiyonu üzerinde kullanılmış, Sentence-BERT MiniLM ile multilingual-E5 modelleri ise önceden eğitilmiş halleriyle değerlendirilmiştir. Tüm yöntemler aynı belge koleksiyonu ve aynı sorgu kümesi üzerinde çalıştırılarak karşılaştırmaların tutarlı olması sağlanmıştır. Her sorgu için en yüksek benzerlik skoruna sahip ilk 10 pasaj elde edilmiş ve ilgili pasajlar, veri kümesindeki ilgililik etiketleri kullanılarak belirlenmiştir. Modellerin başarısı Precision@k, Recall@k, Mean Reciprocal Rank (MRR) ve Normalized Discounted Cumulative Gain (nDCG) ölçütleri kullanılarak değerlendirilmiştir.

Tablo 1'de deneylerde kullanılan veri kümesi, modeller, vektör indeksleme yöntemi ve değerlendirme ölçütleri özetlenmektedir.

Tablo 1. Deneysel kurulumun temel bileşenleri.

Bileşen	Seçim
Veri seti	msmarco-tr (passages / queries / qrels)
Corpus boyutu	40.000 pasaj (958 ilgili + 39.042 distraktör)
Değerlendirme sorgusu	921
Sözlüksel model	BM25Okapi (rank_bm25)
Dense modeller	MiniLM-L12-v2 (384-d), E5-base (768-d), E5-large (1024-d)
Vektör indeksi	FAISS IndexFlatIP (kosinüs)
Metrikler	P@k, R@k, nDCG@k (k = 1, 5, 10) ve MRR

Yoğun vektör tabanlı yöntemlerde, belge ve sorgu temsillerinin benzerlik hesaplamaları FAISS kütüphanesi kullanılarak gerçekleştirilmiştir [9]. Bu sayede, tüm belge koleksiyonunun tek tek taranmasına gerek kalmadan, yüksek boyutlu vektörler arasında hızlı benzerlik araması yapılabilmüş ve özellikle büyük ölçekli koleksiyonlarda hesaplama maliyeti önemli ölçüde azaltılmıştır.

6. Sonuçlar

6.1. Değerlendirme Ölçütleri

Modellerin başarısı Precision@k, Recall@k, Mean Reciprocal Rank (MRR) ve Normalized Discounted Cumulative Gain (nDCG) ölçütleri kullanılarak değerlendirilmiştir. Precision@k, ilk k sonuç içerisinde yer alan ilgili sonuçların oranını; Recall@k, ilgili sonuçların ne kadarının ilk k sonuç içerisinde bulunduğunu göstermektedir. MRR, ilk ilgili sonucun sırasını dikkate alarak ortalama başarıyı ölçerken, nDCG@k ise ilgili sonuçların sıralamadaki konumlarını da dikkate alan sıra duyarlı bir değerlendirme ölçütü sunmaktadır [13].


6.2. Modellerin Karşılaştırılması

Bir sonraki sayfada Tablo 2'de BM25, Sentence-BERT MiniLM, multilingual-E5-base ve multilingual-E5-large modellerinin performansları verilmiştir.

Tablo 2. BM25, Sentence-BERT MiniLM ve multilingual-E5 modellerinin değerlendirme sonuçları.

Model	P@1	R@10	nDCG@10	MRR
BM25	0,4235	0,6589	0,5376	0,5030
SBERT (MiniLM)	0,4017	0,6430	0,5159	0,4785
E5-base	0,7253	0,9240	0,8258	0,7976
E5-large	0,7796	0,9425	0,8630	0,8390

Aşağıdaki Şekil 2'de görüldüğü üzere, BM25 ve MiniLM modelleri benzer performans sergilerken, bilgi erişim görevleri için özel olarak geliştirilen multilingual-E5 modelleri tüm ölçütlerde belirgin biçimde daha yüksek başarı elde etmiştir. Özellikle E5-large modeli, MRR değerinde 0,839 ve Recall@10 değerinde 0,943 ile en yüksek performansı göstermiştir.

**Şekil 2.** Bar grafiği ile uygulanan modellerinin değerlendirme sonuçlarının karşılaştırılması.

Değerlendirme kümesinde sorgu başına ilgili pasaj sayısının büyük çoğunlukla bir olması nedeniyle Precision@10 değerleri doğal olarak düşük kalmıştır. Bu nedenle modeller arasındaki karşılaştırmada Recall@10, MRR ve nDCG@10 ölçütleri daha anlamlı sonuçlar sunmaktadır. Sonuçlar incelendiğinde, genel amaçlı cümle benzerliği modeli olan MiniLM'in BM25 yönteminin dahi gerisinde kaldığı görülmektedir. Buna karşılık, bilgi erişim görevleri için özel olarak geliştirilen multilingual-E5 modelleri önemli ölçüde daha yüksek başarı sağlamıştır. E5-base modelinin BM25'e göre belirgin bir iyileşme sağladığı, E5-large modelinin ise tüm ölçütlerde en iyi sonuçları verdiği görülmektedir. Bu durum, belge getirme problemlerinde başarının yalnızca kullanılan model mimarisine değil, modelin eğitim amacı ve probleme uygunluğuna da bağlı olduğunu göstermektedir.

7. Değerlendirmeler

7.1. Sorgu Tipine Göre Performans Analizi

Modellerin farklı sorgu türlerindeki davranışlarını incelemek amacıyla sorgular uzunluklarına göre kısa (≤ 5 kelime, $n=652$) ve uzun (>5 kelime, $n=269$) olmak üzere iki gruba ayrılmıştır. Kısa sorgularda BM25 yöntemi 0,514 MRR değeri ile MiniLM modelinin (0,459) üzerinde performans göstermiştir. Buna karşılık, uzun sorgularda MiniLM modeli 0,525 MRR değeri ile BM25 yöntemini (0,477) geride bırakmıştır. Bu durum, kısa ve anahtar kelime odaklı sorgularda sözcük eşleşmesine dayalı yöntemlerin avantaj sağlayabildiğini, daha uzun ve açıklayıcı sorgularda ise anlamsal benzerliklerin daha belirleyici hale geldiğini göstermektedir.

Bilgi erişim görevleri için özel olarak geliştirilen multilingual-E5 modelleri ise her iki sorgu grubunda da diğer yöntemlerden daha yüksek başarı elde etmiştir. E5-base modeli kısa sorgularda 0,793, uzun sorgularda ise

0,809 MRR değerine ulaşmıştır. Benzer şekilde, E5-large modeli kısa sorgularda 0,838, uzun sorgularda ise 0,843 MRR değeri elde etmiştir. Her iki model de uzun sorgularda kısa sorgulara kıyasla bir miktar daha yüksek başarı göstermiştir. Ayrıca E5-large modeli, hem kısa hem de uzun sorgularda E5-base modelinin üzerinde performans sergilemiştir.

Elde edilen sonuçlar, kısa sorgularda sözcük tabanlı yöntemlerin belirli avantajlara sahip olduğunu, daha uzun sorgularda ise anlamsal temsillerin önem kazandığını göstermektedir. Bununla birlikte, bilgi erişim görevleri için özel olarak eğitilen multilingual-E5 modellerinin sorgu uzunluğundan bağımsız olarak daha tutarlı ve yüksek performans sağladığı görülmektedir.

Grup	n	BM25 MRR	SBERT MRR
Kısa sorgu (<=5 kelime)	652	0.5138	0.4594
Uzun sorgu (>5 kelime)	269	0.4768	0.5247

=== Sorgu tipine göre MRR (E5-base vs E5-large) ===			
Model	Kısa (<=5)	Uzun (>5)	
E5 (base)	0.7931	0.8086	(n_kısa=652, n_uzun=269)
E5-large	0.8375	0.8427	(n_kısa=652, n_uzun=269)

Şekil 3. Kısa ve uzun sorgular için BM25, Sentence-BERT MiniLM, multilingual-E5-base ve multilingual-E5-large modellerinin MRR değerlerinin karşılaştırılması.

7.2. Somut Üstünlük ve Hata Örnekleri

BM25 ve MiniLM modelleri arasındaki performans farklılıklarını daha ayrıntılı incelemek amacıyla reciprocal rank farkı 0,5'ten büyük olan sorgular analiz edilmiştir. Sonuçlar, 136 sorguda MiniLM modelinin, 157 sorguda ise BM25 yönteminin belirgin biçimde daha başarılı olduğunu göstermiştir. Şekil 4'te her iki yöntemin üstünlük sağladığı bazı örnek sorgular gösterilmektedir.

MiniLM modelinin üstünlük sağladığı örneklerde, sorgu ile ilgili pasaj arasında doğrudan kelime eşleşmesi bulunmamasına rağmen anlamsal olarak benzer ifadelerin yer aldığı görülmektedir. Örneğin, "hiperventilat anlamı" ve "tv şovlarının adının italikleştirilmesi gerekir" sorgularında BM25 ilgili belgeyi üst sıralarda getiremezken, MiniLM modeli ilgili pasajı ilk sırada bulabilmiştir.

Buna karşılık, BM25 yöntemi özellikle özel isimler ve ayırt edici terimler içeren sorgularda daha başarılı sonuçlar üretmiştir. Örneğin, "Orla isminin anlamı" ve "lutheranlar nasıl lent kutlar" sorgularında BM25 ilgili belgeyi ilk sırada getirirken, MiniLM modeli daha düşük başarı göstermiştir. Bu sonuçlar, sözcük tabanlı ve anlamsal yöntemlerin farklı sorgu türlerinde birbirini tamamlayan özelliklere sahip olduğunu göstermektedir.

SBERT belirgin ustun : 136 sorgu BM25 belirgin ustun : 157 sorgu	
=== SBERT kazanıyor (anlamsal / parafraz ilişkisi) ===	
[BM25 RR=0.00 SBERT RR=1.00]	Hangi şehir ördek yavruları için yol yapar kitap gerçekleşir
[BM25 RR=0.00 SBERT RR=1.00]	hiperventilat anlamı
[BM25 RR=0.00 SBERT RR=1.00]	tv şovlarının adının italikleştirilmesi gerekir
=== BM25 kazanıyor (tam kelime / özel isim / sayı) ===	
[BM25 RR=1.00 SBERT RR=0.00]	Orla isminin anlamı
[BM25 RR=1.00 SBERT RR=0.00]	Tarihteki en etkili savaşlar
[BM25 RR=1.00 SBERT RR=0.11]	lutheranlar nasıl lent kutlar


Şekil 4. BM25 ve Sentence-BERT MiniLM modellerinin belirgin üstünlük gösterdiği örnek sorgular. Reciprocal rank farkı 0,5'ten büyük olan sorgular arasından seçilen örneklerde, MiniLM modelinin anlamsal benzerliklerden, BM25 yönteminin ise tam kelime eşleşmelerinden faydalandığı görülmektedir.

7.3. Hibrit (RRF) Deneyi

BM25 ve multilingual-E5-base modellerinin birbirini tamamlayıp tamamlamadığını incelemek amacıyla, iki modelin sıralama sonuçları Reciprocal Rank Fusion (RRF) yöntemi kullanılarak birleştirilmiştir. Şekil 5'te BM25, MiniLM, E5-base ve hibrit BM25+E5 yöntemlerinin performansları karşılaştırılmaktadır.

Sonuçlar, hibrit yaklaşımın tek başına kullanılan E5-base modelinden daha yüksek başarı sağlayamadığını göstermektedir. E5-base modeli MRR ölçütünde 0,798 değerine ulaşırken, BM25+E5 hibrit yöntemi 0,679 MRR değeri elde etmiştir. Benzer şekilde, Recall@10 ve nDCG@10 değerlerinde de hibrit yaklaşım E5-base modelinin gerisinde kalmıştır.

Bu durumun temel nedeni, BM25 yönteminin bu veri kümesinde E5-base modeline göre daha düşük performans göstermesidir. RRF yöntemi her iki modelin sıralamalarını eşit biçimde birleştirdiğinden, daha güçlü olan E5-base modelinin sağladığı avantaj kısmen azalmış ve birleşik sıralama tek başına E5-base modelinin başarısına ulaşamamıştır. Bu sonuç, farklı yöntemlerin birleştirilmesinin her zaman daha yüksek başarı sağlamadığını ve hibrit yaklaşımların ancak birbirini tamamlayan ve benzer düzeyde güçlü yöntemler kullanıldığında daha etkili olabileceğini göstermektedir.



Şekil 5. BM25, Sentence-BERT MiniLM, multilingual-E5-base ve BM25+E5 (RRF) hibrit yöntemlerinin P@10, Recall@10, nDCG@10 ve MRR sonuçlarının karşılaştırılması.

8. Değerlendirmeler

8.1. Yöntemlerin Güçlü ve Zayıf Yönleri

Elde edilen sonuçlar, BM25 ve yoğun vektör tabanlı yöntemlerin farklı avantajlara sahip olduğunu göstermektedir. BM25 yöntemi, özellikle özel isimler ve belirgin anahtar kelimeler içeren sorgularda başarılı sonuçlar vermekte, ayrıca düşük maliyetli ve açıklanabilir bir yapı sunmaktadır. Buna karşılık, farklı ifadelerle aynı anlamı taşıyan sorgularda yetersiz kalabilmektedir. Yoğun vektör tabanlı yöntemler ise anlamsal benzerlikleri daha iyi yakalayarak özellikle uzun ve açıklayıcı sorgularda daha başarılı olmaktadır. Ancak bu yöntemlerin başarısı, kullanılan modelin bilgi erişim görevine uygun olmasına bağlıdır. Bu çalışmada MiniLM modeli BM25'in gerisinde kalırken, retrieval görevleri için geliştirilen multilingual-E5 modelleri belirgin biçimde daha yüksek performans göstermiştir.

8.2. Sınırlılıklar, Etik ve Güvenilirlik

Bu çalışmada kullanılan msmarco-tr veri kümesi, MS MARCO veri setinin Türkçe makine çevirisi ile oluşturulmuştur. Çeviri hataları ve ifade bozuklukları sonuçları etkileyebilmektedir. Ayrıca, sorgu başına ilgili pasaj sayısının genellikle bir olması ve bazı ilgili pasajların koleksiyonda bulunmaması değerlendirme sonuçları üzerinde doğal bir sınırlama oluşturmaktadır. Kullanılan veri kümesi web kaynaklı olduğu için verilerdeki önyargılar sisteme yansiyabilmektedir. Bununla birlikte, çalışmada yalnızca belge getirme işlemi gerçekleştirildiğinden üretken yapay zekâ sistemlerinde görülen yanlış bilgi üretme riski bulunmamaktadır.

9. Sonuç

Bu çalışmada, Türkçe msmarco-tr veri kümesi kullanılarak BM25, Sentence-BERT MiniLM, multilingual-E5-base ve multilingual-E5-large modelleri karşılaştırılmıştır. Modeller aynı belge koleksiyonu ve aynı sorgu kümesi üzerinde Precision@k, Recall@k, MRR ve nDCG ölçütleri kullanılarak değerlendirilmiştir. Sonuçlar, genel amaçlı bir cümle benzerliği modeli olan MiniLM'in BM25 yönteminin gerisinde kaldığını, bilgi erişim görevleri için geliştirilen multilingual-E5 modellerinin ise belirgin biçimde daha yüksek performans sağladığını göstermiştir. En yüksek başarı, MRR=0,839 ve Recall@10=0,943 değerleri ile multilingual-E5-large modeli tarafından elde edilmiştir.

Yapılan hata analizleri, sözcük tabanlı ve anlamsal yöntemlerin farklı sorgu türlerinde birbirini tamamlayan özelliklere sahip olduğunu göstermiştir. Ayrıca, yöntemlerin birleştirilmesinin her zaman daha yüksek başarı sağlamadığı ve model seçiminin belge getirme performansı üzerinde belirleyici bir etkiye sahip olduğu görülmüştür. Gelecekte, yeniden sıralama (re-ranking) yöntemleri, ağırlıklı hibrit yaklaşımlar ve görev odaklı ince ayar (fine-tuning) çalışmaları ile daha yüksek başarı değerlerine ulaşılması mümkün görünmektedir.

Kaynaklar

- [1] C. D. Manning, P. Raghavan, and H. Schütze, **Introduction to Information Retrieval**. Cambridge, U.K.: Cambridge University Press, 2008.
- [2] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," **Foundations and Trends in Information Retrieval**, vol. 3, no. 4, pp. 333–389, 2009.
- [3] V. Karpukhin et al., "Dense passage retrieval for open-domain question answering," in **Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)**, 2020, pp. 6769–6781, arXiv:2004.04906.
- [4] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," arXiv preprint arXiv:2402.05672, 2024.
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186. arXiv:1810.04805.
- [6] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019. arXiv:1908.10084.
- [7] L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, "Text embeddings by weakly-supervised contrastive pre-training," arXiv:2212.03533, 2022.
- [8] A. Conneau et al., "Unsupervised cross-lingual representation learning at scale," in *Proc. ACL*, 2020, pp. 8440–8451. arXiv:1911.02116.
- [9] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, pp. 535–547, 2019.
- [10] T. Nguyen et al., "MS MARCO: A human generated machine reading comprehension dataset," arXiv:1611.09268, 2016.
- [11] L. Bonifacio, V. Jeronymo, H. Q. Abonizio, I. Campiotti, M. Fadaee, R. Lotufo, and R. Nogueira, "mMARCO: A multilingual version of the MS MARCO passage ranking dataset," arXiv:2108.13897, 2021.
- [12] A. Parsak, "MS MARCO-TR: A Turkish adaptation of the MS MARCO passage ranking dataset," *Hugging Face Datasets*, 2024. [Çevrimiçi]. Erişim: <https://huggingface.co/datasets/parsak/msmarco-tr>
- [13] K. Järvelin and J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Trans. Inf. Syst.*, vol. 20, no. 4, pp. 422–446, 2002.
- [14] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, "BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models," in *Proc. NeurIPS Datasets and Benchmarks Track*, 2021.
- [15] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal rank fusion outperforms Condorcet and individual rank learning methods," in *Proc. ACM SIGIR*, 2009, pp. 758–759.

Ekler

- **Kaynak kod:** Tüm hücreleri çıktılarıyla birlikte çalıştırılmış, tekrar üretilebilir Jupyter notebook (BM25, MiniLM, E5-base, E5-large, RRF hibrit). GitHub bağlantısı README.md içinde verilmiştir.

Yapay zekâ kullanım beyanı. Projenin kodlama ve raporlama aşamalarında bir yapay zekâ asistanından yöntem seçimi, kod iskeleti ve metin düzenleme konusunda destek alınmıştır. Tüm deneyler öğrenci tarafından çalıştırılmış, sonuçlar doğrulanmış ve yorumlar gözden geçirilmiştir.